

Algorithmes : Analyse Factorielle (AF) et Analyse en Composantes Principales (ACP)

Analyse Factorielle

Input :

- $X_1, X_2, \dots, X_n \in \mathbb{R}^p$
- $m_1, m_2, \dots, m_n \in \mathbb{R}$

Output :

- $X_1, X_2, \dots, X_n \in \mathbb{R}^q (q < p)$
- $m_1, m_2, \dots, m_n \in \mathbb{R}$

Input

n points dans un s.e.v S de dimension p

➔ Perte d'information : à Minimiser

Distance_S(Xi, Xj)

➔ Output

➔ n points dans un s.e.v P de dimension q

< Distance_P(Xi, Xj)

L'analyse factorielle consiste à trouver le s.e.v P qui minimise :

$$\sum_{i=1}^n \sum_{j=1}^n m_i \cdot m_j \cdot \left(d^2(X_i, X_j) - d^2(\text{Proj}_P(X_i), \text{Proj}_P(X_j)) \right)$$

$$= \sum_{i=1}^n \sum_{j=1}^n m_i \cdot m_j \cdot d^2(X_i, X_j) - \underbrace{\sum_{i=1}^n \sum_{j=1}^n m_i \cdot m_j \cdot d^2(\text{Proj}_P(X_i), \text{Proj}_P(X_j))}_{\text{à maximiser}}$$

Pour trouver P , on doit chercher q axes Δ_i avec :

Δ_1 tel que Δ_1 passe par O et $I_E(\Delta_1)$ est maximale

Δ_2 tel que Δ_2 passe par O , $\Delta_1 \perp \Delta_2$ et $I_E(\Delta_2)$ est maximale

.

Δ_q tel que Δ_q passe par O , $\Delta_1 \perp \Delta_q$, $\Delta_2 \perp \Delta_q$ etc. et $I_E(\Delta_q)$ est maximale

Si la dimension de P n'est pas fixée, on fixe un seuil (c.à.d un pourcentage de l'inertie du nuage) et on cherche la valeur de q minimale tel que $I_E(P) \geq \text{seuil}$ (exemple seuil= 80% de $I(O)$).

➔ Les axes factoriels $\Delta_1 \dots \Delta_q$ sont les axes passant par l'origine et dont les vecteurs directeurs sont les q premiers vecteurs propres de la matrice $V=X'.M.X$

$$X = \begin{pmatrix} X_{11} & \dots & X_{1p} \\ \vdots & & \vdots \\ X_{i1} & \dots & X_{ip} \\ \vdots & & \vdots \\ X_{n1} & \dots & X_{np} \end{pmatrix} \begin{matrix} \leftarrow X_1 \\ \vdots \\ \leftarrow X_i \\ \vdots \\ \leftarrow X_n \end{matrix} \text{ de taille } (n,p) \text{ et } M = \begin{pmatrix} m_1 & 0 & \dots & 0 \\ 0 & \ddots & \ddots & \vdots \\ \vdots & \ddots & \ddots & 0 \\ 0 & \dots & 0 & m_n \end{pmatrix} \text{ de taille } (n,n)$$

➔ C'est-à-dire, $V = A D A'$ (A' =transposé(A)) avec A la matrice des vecteurs propres (U_1, \dots, U_p) et D la matrice des valeurs propres ($\lambda_1, \dots, \lambda_p$) tel que $\lambda_1 > \lambda_2 > \dots > \lambda_p$

L'inertie expliquée par chaque axe factoriel Δ_t est égale à la valeur propre λ_t correspondante à son vecteur directeur (i.e. vecteur propre U_t)

```
void XN[n][q] ← AF_Cas1(void X[n][p], float M[n][n], int q)
```

```
BEGIN
```

```
V ← X'.M.X
```

```
//X'=transposé(X)
```

```
[v1...vp, λ1... λp] ← Diagonalise(V)
```

```
// V=P.A.P' avec P est la matrice des vecteurs propres v1 ... vp et A la matrice des valeurs  
// propres λ1 ... λp (λ1> λ2> ...> λp)
```

```
Axe-Fact1 ← Droite passant par l'origine et dont le vecteur directeur est v1 et son inertie  
expliqué est égal à λ1
```

```
Axe-Fact2 ← Droite passant par l'origine et dont le vecteur directeur est v2 et son inertie  
expliqué est égal à λ2
```

```
...
```

```
Axe-Factq ← Droite passant par l'origine et dont le vecteur directeur est vq et son inertie  
expliqué est égal à λq
```

```
Pour i=1 ...n
```

```
    Pour k=1...q
```

```
        XN[i][k]=produit_scalaire(X[i][:],vk)
```

```
        //le coordonnée de l'individu Xi sur Axe_Fack est égal à son produit scalaire avec le
```

```
        // vecteur directeur de cet axe (=kème vecteur propre vk)
```

```
    Finpour
```

```
Finpour
```

```
END
```

void XN[n][q] \leftarrow AF_Cas2(void X[n][p], float M[n][n], float seuil)

BEGIN

$V \leftarrow X'.M.X$

//X'=transposé(X)

[v1...vp, $\lambda_1 \dots \lambda_p$] \leftarrow Diagonalise(V)

// V=P.A.P' avec P est la matrice des vecteurs propres v1 ... vp et A la matrice des valeurs

// propres $\lambda_1 \dots \lambda_p$ ($\lambda_1 > \lambda_2 > \dots > \lambda_p$)

Axe-Fact1 \leftarrow Droite passant par l'origine et dont le vecteur directeur est v1 et son inertie expliqué est égal à λ_1

Si $\lambda_1/\text{somme}(\lambda_1 \dots \lambda_p) \geq \text{seuil}$ alors q=1

Sinon Axe-Fact2 \leftarrow Droite passant par l'origine et dont le vecteur directeur est v2 et son inertie expliqué est égal à λ_2

Si $(\lambda_1 + \lambda_2)/\text{somme}(\lambda_1 \dots \lambda_p) \geq \text{seuil}$ alors q=2

Sinon Axe-Fact3 \leftarrow Droite passant par l'origine et dont le vecteur directeur est v3 et son inertie expliqué est égal à λ_3

....

Pour i=1 ...n

Pour k=1...q

$XN[i][k] = \text{produit_scalaire}(X[i][:], v_k)$

//le coordonnée de l'individu Xi sur Axe_Factk est égal à son produit scalaire avec le

// vecteur directeur de cet axe (=kème vecteur propre vk)

Finpour

Finpour

END

Analyse en Composantes Principales

Input : $X_1, X_2, \dots, X_n \in \mathbb{R}^p$ ($m_1=m_2=\dots=m_n = 1/n$)

Output : $X_1, X_2, \dots, X_n \in \mathbb{R}^q$ ($q < p$)

Step 0 : Centrer et Réduire la population

$$X_{ij} \rightarrow (X_{ij} - \text{moy}(\text{Att}_j)) / \text{ecart_type}(\text{Att}_j)$$

Ainsi, $\text{moy}(\text{Att}_j) = 0$

et $\text{ecart_type}(\text{Att}_j) = 1$

➔ La matrice à diagonaliser V n'est autre que la matrice des coefficients des corrélations linéaires des p attributs (qui est symétrique avec des valeurs égales à 1 sur le diagonal)

En plus, puisque $V = A D A'$, on a $\text{trace}(V) = \text{trace}(D) \rightarrow p = \lambda_1 + \dots + \lambda_p$

void XN[n][q] ← ACP_Cas1(float X[n][p], float M[n][n]=(1/n).1I_{nxn}, int q)

BEGIN

V ← Matrice des Coefficients des Corrélations Linéaires des p attributs

[v1...vp, λ1... λp] ← Diagonalise(V)

// V=P.A.P' avec P est la matrice des vecteurs propres v1 ... vp et A la matrice des valeurs
// propres λ1 ... λp (λ1> λ2> ...> λp), sachant que somme(λ1,..., λp)=p

Axe-Fact1 ← Droite passant par l'origine et dont le vecteur directeur est v1 et son inertie
expliqué est égal à λ1

Axe-Fact2 ← Droite passant par l'origine et dont le vecteur directeur est v2 et son inertie
expliqué est égal à λ2

...

Axe-Factq ← Droite passant par l'origine et dont le vecteur directeur est vq et son inertie
expliqué est égal à λq

Pour i=1 ...n

 Pour k=1...q

 XN[i][k]=produit_scalaire(X[i][:],vk)

 //le coordonnée de l'individu Xi sur Axe_Factk est égal à son produit scalaire avec le

 // vecteur directeur de cet axe (=kème vecteur propre vk)

 Finpour

Finpour

END

void XN[n][q] \leftarrow ACP_Cas2(float X[n][p], float M[n][n]=(1/n).1I_{nxn}, float seuil)

BEGIN

V \leftarrow Matrice des Coefficients des Corrélations Linéaires des p attributs

[v1...vp, λ_1 ... λ_p] \leftarrow Diagonalise(V)

// V=P.A.P' avec P est la matrice des vecteurs propres v1 ... vp et A la matrice des valeurs

// propres λ_1 ... λ_p ($\lambda_1 > \lambda_2 > \dots > \lambda_p$), sachant que somme($\lambda_1, \dots, \lambda_p$)=p

Axe-Fact1 \leftarrow Droite passant par l'origine et dont le vecteur directeur est v1 et son inertie expliqué est égal à λ_1

Si $\lambda_1/p \geq$ seuil) alors q=1

Sinon Axe-Fact2 \leftarrow Droite passant par l'origine et dont le vecteur directeur est v2 et son inertie expliqué est égal à λ_2

Si $(\lambda_1 + \lambda_2)/p \geq$ seuil) alors q=2

Sinon Axe-Fact3 \leftarrow Droite passant par l'origine et dont le vecteur directeur est v3 et son inertie expliqué est égal à λ_3

....

Pour i=1 ...n

Pour k=1...q

XN[i][k]=produit_scalaire(X[i][:],vk)

//le coordonnée de l'individu Xi sur Axe_Fack est égal à son produit scalaire avec le

// vecteur directeur de cet axe (=kème vecteur propre vk)

Finpour

Finpour

END