

# Data Analysis

$lw = \text{Sum}(m.d^2(\text{Point}, \text{Centre du gravité du classe auquel il appartient}))$

$lb = m.\text{Sum}(m.Nb\_points\_classe * d^2(\text{Centre de gravité classe, centre de gravité global}))$

$l(G) = \text{Sum}(m.d^2(\text{point, centre de gravité global}))$

Matrice de ward :

$\text{gamma}(Mi, Mj) = (mi * mj / mi + mj) * d^2(Mi, Mj)$

## Modèle Linéaire Simple

Exemple (suite) :

$i$ (ind.)	$y_i$ (revenu)	$x_i$ (âge)	$y_i - \bar{y}$	$x_i - \bar{x}$	$(x_i - \bar{x})(y_i - \bar{y})$	$(x_i - \bar{x})^2$
1	52125.0	48.1	193.9	5.0	978.6	25.5
2	50955.9	38.7	-975.3	-4.4	4245.4	18.9
3	53382.9	48.6	1451.7	5.6	8061.1	30.8
4	51286.9	37.5	-644.3	-5.5	3570.3	30.7
5	55243.6	54.7	3312.5	11.6	38434.3	134.6
6	53384.7	40.7	1453.5	-2.4	-3481.4	5.7
7	53488.2	50.1	1557.1	7.1	10982.0	49.7
8	54134.1	45.9	2202.9	2.9	6281.9	8.1
9	52706.4	55.9	775.2	12.9	9975.6	165.6
10	42144.3	25.1	-9786.9	-18.0	176033.4	323.5
11	52665.2	36.9	734.1	-6.1	-4503.3	37.6
12	51656.7	34.5	-274.5	-8.6	2350.7	73.3
Moyenne	51931.2	43.1	0	0	21077.4	75.4
Somme	623174.0	516.8	0	0	252928.4	904.3

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{252928.4}{904.3} = 279.7$$

$$\hat{\beta}_0 = 51931.2 - 279.7 * 43.1 \cong 39885$$

cov var

Beta1\_chapeau = cov/var(x)

Beta0\_chapeau = y\_bar - beta1\_chapeau \* x\_bar

Y\_chapeau = beta0\_chapeau + beta1\_chapeau \* x

Variance = 1/n \* somme (x - xbar)<sup>2</sup>

Cov = 1/n \* somme (x-xbar)(y-ybar)

Coef Corr = cov/racine(variance) \* racine(variance)


**Calcul SCR :**

$i$ (ind.)	$y_i$ (revenu)	$x_i$ (âge)	$\hat{y}_i = 39885 + 279.7 * x_i$	$y_i - \hat{y}_i$	$(y_i - \hat{y}_i)^2$
1	52125.0	48.1	53343.0	-1218.0	1483550.6
2	50955.9	38.7	50713.7	242.2	58675.3
3	53382.9	48.6	53484.3	-101.4	10274.8
4	51286.9	37.5	50381.1	905.8	820405.6
5	55243.6	54.7	55176.5	67.1	4507.4
6	53384.7	40.7	51261.3	2123.5	4509068.6
7	53488.2	50.1	53903.9	-415.6	172735.6
8	54134.1	45.9	52728.7	1405.4	1975015.2
9	52706.4	55.9	55530.2	-2823.8	7973726.7
10	42144.3	25.1	46900.3	-4756.1	22620189.0
11	52665.2	36.9	50215.3	2450.0	6002285.9
12	51656.7	34.5	49535.7	2121.0	4498484.4
Moyenne	51931.2	43.1	51931.2	0	4177409.1
Somme	623174.0	516.8	623174.0	0	50128909.0

SCR = (somme des epsilon)<sup>2</sup>

On note l'expression suivante :  $R^2 = \frac{SCE}{SCT}$  Avec

$$SCT = \sum_{i=1}^n (y_i - \bar{y})^2 = m_{YY} \quad SCE = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 = \hat{\beta}_1^2 m_{XX} \quad SCR = \sum_{i=1}^n \hat{\epsilon}_i^2 = m_{YY} - \hat{\beta}_1^2 m_{XX}$$



$$\sum_i (y_i - \bar{y})^2 = \sum_i (y_i - \hat{y}_i)^2 + \sum_i (\hat{y}_i - \bar{y})^2$$

$$SCT = SCR + SCE$$

Décomposition de la variance

*SCT* : somme des carrés totaux

*SCE* : somme des carrés expliqués par le modèle

*SCR* : somme des carrés résiduels, non expliqués par le modèle

#### IV – Validation du modèle : coefficient de détermination $R^2$

**Coefficient de détermination.**

**Exprime la part de variabilité de Y expliquée par le modèle.**

$R^2 \rightarrow 1$ , le modèle est excellent

$R^2 \rightarrow 0$ , le modèle ne sert à rien

$$R^2 = \frac{SCE}{SCT}$$

$$R^2 = 1 - \frac{SCR}{SCT}$$

SCE représente la variation expliquée.

SCR représente la variation inexpliquée due aux variables omises dans le modèle.

Si  $R^2=0,9$  ; on dit que 90% de la variation de **X** est expliquée par la variation de **Y** .

Si  $R^2=0,1$  ; la variation de **X** contribue à hauteur de 10% dans l'explication de la variation de **Y**. Par conséquent, la variable explicative ne suffit pas à elle seule à expliquer la variable expliquée . On doit dans ce cas introduire d'autres variables dans le modèle sans pour autant rejeter automatiquement la variable **X**. Ce qu'on appelle modèle linéaire multiple

Modèle linéaire multiple :